

Regresión cuantílica: de la media a toda la distribución

Julián David Hernández Grisales

14 de septiembre de 2026

Índice

1. Introducción y motivación	2
2. Regresión lineal clásica	3
3. La limitación de una sola curva	3
4. ¿Qué podemos hacer en lugar de estudiar solo la media?	3
5. Regresión cuantílica	4
6. Historia y motivación	4
7. ¿Cómo estimamos un cuantil?	5
8. La mediana y el valor absoluto	5
9. De la mediana a cualquier cuantil	6
10. La función check loss	6
11. Función objetivo de la regresión cuantílica	6
12. La idea completa	7
13. Modelo de regresión cuantílica	7
14. Interpretación de los coeficientes	7
15. Una covariable puede tener efectos diferentes	8
16. Regresión lineal vs. regresión cuantílica	8
17. Leer las curvas cuantílicas	9
18. Precisión importante	9
19. ¿Por qué resulta útil frente a valores extremos?	9
20. Otra ventaja: observar la dispersión	9
21. ¿Qué supuestos evitamos imponer?	9
22. Estimar no es suficiente	10

23.¿Qué no podemos concluir?	10
24.Precaución: cruce de cuantiles	10
25.¿Cuándo es especialmente útil?	10
26.Conclusión	11
27.Visualizaciones relevantes	11
28.Aplicaciones	11
29.Referencias	12

1. Introducción y motivación

La regresión lineal clásica estudia cómo cambia la variable respuesta Y cuando cambian las covariables X . Su objetivo principal es modelar la media condicional:

$$E(Y \mid X = x).$$

Sin embargo, una sola curva puede ocultar información importante sobre la distribución completa de Y . En muchos contextos, la relación entre X y Y no es igual en todas las partes de la distribución: puede ser distinta en los valores bajos, medios y altos.

Por esta razón, resulta útil estudiar no solo la media, sino también otros puntos de la distribución condicional, como los cuantiles:

$$Q_Y(\tau \mid X = x), \quad \tau \in (0, 1).$$

Esto lleva al enfoque de la regresión cuantílica.




Figura 1: La media describe el centro, pero no toda la distribución.

2. Regresión lineal clásica

La regresión lineal clásica parte del modelo:

$$Y = X\beta + \varepsilon.$$

El objetivo principal es estimar la media condicional:

$$E(Y \mid X = x).$$

La pregunta central es la siguiente:

¿Cómo cambia la media de Y cuando cambia X ?

En esta formulación, todos los efectos se resumen en un solo promedio. Esto es útil cuando la atención está centrada en el comportamiento central de la variable, pero puede ser insuficiente cuando se desea entender la variabilidad, la asimetría o los valores extremos.

3. La limitación de una sola curva

Una sola curva puede no mostrar toda la estructura de la distribución condicional de Y .

Una sola curva $\longrightarrow$ visión parcial

Varias curvas $\longrightarrow$ visión más completa

La media resume, pero no necesariamente cuenta toda la historia. En muchos problemas relevantes, el comportamiento en la cola inferior y en la cola superior es diferente del comportamiento en el centro.

4. ¿Qué podemos hacer en lugar de estudiar solo la media?

En lugar de estudiar únicamente la media:

$$E(Y \mid X = x),$$

podemos estudiar diferentes puntos de la distribución condicional:

$$Q_Y(\tau \mid X = x),$$

donde $\tau \in (0, 1)$ representa el cuantil de interés.

Por ejemplo:

$$\tau = 0,10, \quad \tau = 0,25, \quad \tau = 0,50, \quad \tau = 0,75, \quad \tau = 0,90.$$

Estos valores corresponden a los percentiles 10 %, 25 %, 50 % (mediana), 75 % y 90 %.

10 %	25 %	Mediana	75 %	90 %
------	------	----------------	------	------

5. Regresión cuantílica

La regresión cuantílica permite modelar directamente los cuantiles condicionales de Y :

$$Q_Y(\tau | X = x) = \beta_0(\tau) + \beta_1(\tau)x_1 + \cdots + \beta_p(\tau)x_p.$$

Una característica central es que los coeficientes pueden depender del cuantil:

$$\beta_j(0,10) \neq \beta_j(0,50) \neq \beta_j(0,90).$$

Esto implica que la relación entre X y Y puede ser distinta en distintas partes de la distribución.




Figura 2: Curvas cuantílicas representando distintas partes de la distribución condicional.

6. Historia y motivación

La regresión cuantílica fue formulada por Koenker y Bassett en 1978 como una extensión de los cuantiles muestrales al contexto de modelos condicionales.

De la media $\longrightarrow$ a diferentes cuantiles

El ejemplo clásico de Engel relaciona el ingreso del hogar con el gasto en alimentos. En un conjunto de hogares, observar solo la media puede ocultar diferencias entre hogares con gastos bajos, medios y altos.




Figura 3: Ejemplo de Engel: ingreso del hogar y gasto en alimentos.

7. ¿Cómo estimamos un cuantil?

La media se estima mediante la minimización de errores cuadrados:

$$\hat{\mu} = \arg \min_{\mu} \sum_{i=1}^n (y_i - \mu)^2.$$

El minimizador es la media muestral:

$$\hat{\mu} = \bar{y}.$$

Entonces aparece una pregunta natural:

¿Existe una función de pérdida cuyo minimizador sea un cuantil?

8. La mediana y el valor absoluto

Para la mediana, la estimación se obtiene como:

$$\hat{Q}_{0,5} = \arg \min_a \sum_{i=1}^n |y_i - a|.$$

En contraste:

$$\bar{y} = \arg \min_a \sum_{i=1}^n (y_i - a)^2.$$

Por tanto, los objetivos son distintos:

Cuadrados → Media,

Valor absoluto → Mediana.

9. De la mediana a cualquier cuantil

La mediana trata de manera simétrica los residuos positivos y negativos. Para obtener otros cuantiles se requieren pesos asimétricos.

$$\tau \neq 0,5 \implies \text{pérdida asimétrica.}$$

La función de pérdida cuantilica es:

$$\rho_\tau(u) = u [\tau - \mathbb{I}(u < 0)],$$

o equivalentemente:

$$\rho_\tau(u) = \begin{cases} \tau u, & u \geq 0, \\ (\tau - 1)u, & u < 0. \end{cases}$$




Figura 4: Función check loss para distintos valores de τ .

10. La función check loss

La penalización cambia según el signo del residuo. Si $\tau \neq 0,5$, los errores positivos y negativos tienen un peso distinto.

$$\tau \neq 0,5 \implies \text{errores positivos y negativos pesan distinto.}$$

Por ejemplo, para $\tau = 0,90$:

penalización por subestimar $>$ penalización por sobreestimar.

11. Función objetivo de la regresión cuantilica

Definimos el residuo:

$$u_i = y_i - x_i^\top \beta.$$

Entonces buscamos los coeficientes que minimizan la pérdida cuantilica total:

$$\hat{\beta}(\tau) = \arg \min_{\beta \in \mathbb{R}^p} \sum_{i=1}^n \rho_{\tau}(y_i - x_i^{\top} \beta)$$

donde

$$\rho_{\tau}(u) = u[\tau - \mathbb{I}(u < 0)].$$

12. La idea completa

La relación entre la pérdida y el tipo de resumen estadístico es la siguiente:

$$\boxed{\sum u_i^2} \longrightarrow E(Y \mid X)$$

$$\boxed{\sum \rho_{\tau}(u_i)} \longrightarrow Q_Y(\tau \mid X)$$

En otras palabras:

$$\boxed{\text{Cuadrados}} \longrightarrow \text{Media}$$

$$\boxed{\text{Valor absoluto}} \longrightarrow \text{Mediana}$$

$$\boxed{\rho_{\tau}(u)} \longrightarrow \text{Cuantil } \tau$$

13. Modelo de regresión cuantílica

Una vez definidos los cuantiles condicionales, el modelo puede plantearse como:

$$Q_Y(\tau \mid X = x) = \beta_0(\tau) + \beta_1(\tau)x_1 + \cdots + \beta_p(\tau)x_p.$$

O en forma matricial:

$$Q_Y(\tau \mid X) = X\beta(\tau).$$

La estimación se obtiene mediante:

$$\hat{\beta}(\tau) = \arg \min_{\beta} \sum_{i=1}^n \rho_{\tau}(y_i - x_i^{\top} \beta)$$

14. Interpretación de los coeficientes

Consideremos el caso simple:

$$Q_Y(\tau \mid X) = \beta_0(\tau) + \beta_1(\tau)X.$$

Entonces:

$$\boxed{\beta_1(\tau)}$$

representa el cambio en el cuantil τ de Y ante un aumento de una unidad en X .
Por ejemplo:

$$\beta_1(0,90) = 2$$

significa que, manteniendo constantes las demás covariables, un aumento de una unidad en X está asociado con un incremento de dos unidades en el cuantil 90 % condicional de Y .

15. Una covariable puede tener efectos diferentes

$$Q_Y(0,10 | X) = \beta_0(0,10) + \beta_1(0,10)X$$

$$Q_Y(0,50 | X) = \beta_0(0,50) + \beta_1(0,50)X$$

$$Q_Y(0,90 | X) = \beta_0(0,90) + \beta_1(0,90)X$$

Por tanto:

$$\boxed{\beta_1(0,10) \neq \beta_1(0,50) \neq \beta_1(0,90).}$$

Esto permite estudiar heterogeneidad en la relación entre X y Y .

16. Regresión lineal vs. regresión cuantílica

Aspecto	Regresión lineal	Regresión cuantílica
Objetivo	Modela la media condicional	Modela cuantiles condicionales
Estructura estimada	$E(Y X)$	$Q_Y(\tau X)$
Pérdida utilizada	Mínimos cuadrados	Check loss o pérdida asimétrica
Función objetivo	$\sum_i u_i^2$	$\sum_i \rho_\tau(u_i)$
Interpretación	Efecto promedio sobre Y	Efecto en un cuantil específico
Sensibilidad	Más influenciada por valores extremos	Más robusta para estudiar colas

Cuadro 1: Comparación entre regresión lineal y regresión cuantílica.

La regresión lineal responde a la pregunta:

¿cómo cambia el promedio de Y cuando cambia X ?

La regresión cuantílica responde a una pregunta más rica:

¿cómo cambia cada parte de la distribución de Y cuando cambia X ?

$\boxed{\text{Media promedio vs. distribución completa}}$

17. Leer las curvas cuantílicas

Supongamos que estimamos tres cuantiles importantes:

$$Q_{0,10}(Y | X), \quad Q_{0,50}(Y | X), \quad Q_{0,90}(Y | X).$$

Estos permiten estudiar varios aspectos como la posición, la dispersión, la asimetría y la heterogeneidad.

Posición

Dispersión

Asimetría

Heterogeneidad

La separación entre curvas aporta información sobre cómo cambia la distribución condicional.

18. Precisión importante

La regresión cuantílica no consiste en dividir la muestra en grupos y ajustar una regresión en cada grupo.

$$\text{No: } Y_{\text{bajo}}, Y_{\text{medio}}, Y_{\text{alto}}$$

En cambio, se modela directamente:

$$Q_Y(\tau | X)$$

condicionando en las covariables X .

19. ¿Por qué resulta útil frente a valores extremos?

La regresión por mínimos cuadrados usa la función u^2 , por lo que los residuos grandes reciben un peso cada vez mayor. En cambio, la regresión cuantílica usa $\rho_\tau(u)$, que es lineal por tramos.

$$\text{Menor sensibilidad a observaciones extremas}$$

La regresión cuantílica no elimina los valores extremos; los integra dentro del estudio de la distribución.

20. Otra ventaja: observar la dispersión

Cuando las curvas cuantílicas se separan conforme cambia X , la diferencia

$$Q_{0,90}(Y | X) - Q_{0,10}(Y | X)$$

puede aumentar. Esto puede revelar cambios en la dispersión condicional.

$$\text{Distancia entre cuantiles} \rightarrow \text{información sobre dispersión}$$

21. ¿Qué supuestos evitamos imponer?

La regresión cuantílica no necesita asumir que

$$Y | X \sim N(\mu, \sigma^2)$$

para definir el cuantil condicional. En lugar de especificar una distribución completa, modela directamente $Q_Y(\tau | X)$.

Esto permite capturar asimetría, heterocedasticidad y colas pesadas de modo más directo.

asimetría heterocedasticidad colas

22. Estimar no es suficiente

Una vez obtenida la estimación $\hat{\beta}(\tau)$, es necesario preguntarse:

¿Qué tan precisa es esta estimación?

Se pueden estudiar:

Errores estándar, intervalos de confianza, pruebas de hipótesis.

Una alternativa muy utilizada es el bootstrap.

23. ¿Qué no podemos concluir?

Que $\beta_j(\tau) \neq 0$ no implica causalidad. Además, no debemos asumir que los coeficientes en distintos cuantiles deben ser iguales.

La regresión cuantilica describe asociaciones condicionales en distintas partes de la distribución, no necesariamente relaciones causales.

24. Precaución: cruce de cuantiles

Al estimar los cuantiles de manera independiente, puede ocurrir que

$$\hat{Q}_Y(0,90 | X) < \hat{Q}_Y(0,50 | X)$$

para algún valor de X .

Esto no es deseable, porque los cuantiles deben respetar el orden:

$$Q_Y(0,10 | X) \leq Q_Y(0,50 | X) \leq Q_Y(0,90 | X).$$

Los cuantiles deben respetar su orden.

25. ¿Cuándo es especialmente útil?

La regresión cuantilica es especialmente informativa cuando se desean estudiar:

Heterogeneidad

Asimetría

Heterocedasticidad

Colas de la distribución

Valores extremos

Porque la pregunta ya no es solamente

$$E(Y | X),$$

sino

$$Q_Y(\tau | X), \quad 0 < \tau < 1.$$

26. Conclusión

Las cinco ideas centrales son:

1. La media no siempre cuenta toda la historia

2. Los cuantiles permiten mirar diferentes posiciones

3. La regresión cuantilica modela $Q_Y(\tau | X)$

4. La check loss define su estimación

5. Los coeficientes pueden cambiar con τ

En resumen:

De una sola curva $\rightarrow$ una imagen más completa de la distribución

27. Visualizaciones relevantes



Figura 5: Representación visual de la comparación entre centralidad y distribución completa.

28. Aplicaciones

Ejemplo 1: marketing. El cuantil bajo ayuda a estudiar escenarios conservadores; el alto, capacidad potencial. La diferencia entre curvas describe heterogeneidad en la respuesta.

Ejemplo 2: salarios. La educación puede tener un efecto distinto en la cola baja y en la cola alta. Un único promedio puede ocultar desigualdad.

Ejemplo 3: salud. En peso al nacer, la misma covariable puede afectar de forma distinta a bebés con riesgo bajo y alto.

Ejemplo 4: rendimiento y riesgo. En finanzas, cuantiles bajos modelan pérdidas extremas; en energía, cuantiles altos ayudan a planear demanda.

29. Referencias

- Koenker, R. y Bassett, G. (1978). *Regression Quantiles*. *Econometrica*.
- Koenker, R. y Hallock, K. (2001). *Quantile Regression*. *Journal of Economic Perspectives*.
- Koenker, R. (2005). *Quantile Regression*. Cambridge University Press.
- Material académico incluido en `documentacion/Documentación_Q.pdf`.